

CNN ile Göz Hastalıkları Teşhisi

ODIR-5K Veri Seti Üzerinde Derin Öğrenme Yaklaşımı

| Proje Tanımı ve Amaç

Bu çalışmanın temel amacı, hastaların fundus göz resimlerinden **aynı anda sahip olabilecekleri birden fazla göz hastalığını eş zamanlı ve otomatik olarak tespit edebilen**, yüksek doğruluklu bir çoklu etiketli (multi-label) CNN modeli geliştirmektir.

Geleneksel tek etiketli sınıflandırma modellerinin aksine bu yaklaşım, medikal gerçekliğe uygun olarak bir hastanın retinasında hem katarakt hem de diyabetik retinopati gibi farklı patolojilerin bir arada bulunma durumunu bağımsız olarak analiz edip her bir hastalık için ayrı olasılık skorları üretmeyi hedefler.



| ODIR-5K Veri Seti: Genel Bakış

Ocular Disease Intelligent Recognition (ODIR), 5.000 hastaya ait yaş, cinsiyet ve fundus fotoğraflarını içeren yapılandırılmış bir veritabanıdır.

Gerçek Dünya Verisi

Çin'deki farklı hastanelerden Shanggong Medical Technology tarafından toplanmıştır.

Kamera Çeşitliliği

Canon, Zeiss ve Kowa gibi markaların kameralarıyla farklı çözünürlüklerde çekilmiştir.

Teşhis Süreci

Klinik doktorlar tarafından sağlanan "Diagnostic Keywords" temel alınarak etiketlenmiştir.



| Sınıflandırma Etiketleri



Normal (N)

Sağlıklı göz yapısı



Diyabet (D)

Diyabetik Retinopati



Glokom (G)

Göz tansiyonu



Katarakt (C)

Lens bulanıklığı



AMD (A)

Makula Dejenerasyonu



Hipertansiyon (H)

Vasküler hasar



Miyopi (M)

Patolojik miyopi



Diğer (O)

Diğer anormallikler


| Sınıf Dağılımı ve Veri Dengesizliği



Veride belirgin bir **dengesizlik** mevcuttur.

En fazla 'Normal' (2873), en az 'Hipertansiyon' (128) hastası bulunmaktadır.

Görüntü Başına Etiket Sayısı Dağılımı




Bu grafik her görüntü için kaç etiket bulunduğunu gösterir, veri setinin **Çoklu Etiketli (Multi-label)** doğasını kanıtlar.

Çoğu görüntüde 1 etiket olsa da, bazı görüntülerde **2 veya 3 hastalığın** aynı anda bulunduğunu göstermektedir.

Veri setindeki göz hastalıklarının bir arada bulunma sıklığını temsil eder.

Veri Görselleştirme Örnekleri




Fundus görüntüleri model eğitimi için önceden işlenmiş versiyonlardır.

Veri Önışleme ve Hazırlık

Ham Veriden Modele Geçiş Süreci

| Veri Seti Çıkarılması ve Ortam

-  Projede kullanılan ham retina fundus görüntüleri **preprocessed_images.zip** arşivinden otomatik çıkarılmıştır.
-  Python betikleri ve zipfile kütüphanesi ile hızlı veri erişimi sağlanmıştır.
-  **Ortam Hazırlığı:** Pandas, NumPy ve TensorFlow kütüphaneleri optimize edilerek GPU desteği ile yapılandırılmıştır.



| Çoklu Etiketlerin Hazırlanması

Binary Matris Yapısı

Her göz resmi için 8 bağımsız sütundan oluşan bir hedef vektörü oluşturulmuştur:

[1, 0, 0, 0, 1, 0, 0, 0]

Neden Önemli?

- Softmax yerine **sigmoid çıkışı** alabilmek için verinin bu formatta olması şarttır.
- Bu yapı, modelin her bir hastalığı diğerlerinden bağımsız olarak değerlendirmesini sağlar.
- "**Independent indicator**" (bağımsız gösterge) formatı çoklu etiketli sınıflandırma için temeldir.

ETİKET YÖNETİMİ: Verinin model tarafından doğru yorumlanması için yapısal dönüşüm süreci.

| Görüntü Standardizasyonu

224x224

Giriş Katmanı Boyutu


Tüm görüntüler **EfficientNetB0** giriş boyutuna (224x224) getirilerek optimize edilmiştir.

Standardizasyonun Faydaları

- Boyutlar arası **tam tutarlılık** sağlandı.
- Retina dışındaki siyah bölgeler kırpılarak **gürültü azaltıldı**.
- Modelin **öğrenme hızı** ve bellek kullanımı optimize edildi.

VERİ HAZIRLIĞI: Model verimliliğini artırmak için yapısal görüntü düzenleme süreci.

Kontrast İyileştirme (CLAHE)




Doku Belirginleştirme

- Kılcal damarlar ve mikro-kanamalar gibi ince detayların çoklu teşhislerde gözden kaçmaması için **CLAHE** algoritması kullanıldı.
- Düşük ışıklı çekimlerde bile lezyonlar ayırt edilebilir hale getirildi.
- Piksel yoğunluğu dağıtılarak **yerel kontrast** maksimize edildi.

GÖRÜNTÜ İŞLEME: Teşhis doğruluğunu artırmak için dokusal detayların vurgulanması süreci.

| Veri Artırma (Augmentation)



Çeşitlilik ve Dayanıklılık


Modelin farklı çekim açılarına karşı bağışıklık kazanması için:

- **Rastgele döndürme** (Rotation)
- **Yatay çevirme** (Horizontal Flip)
- **Parlaklık ve kontrast** değişimleri

Bu sayede model, sınırlı veriye rağmen **"ezberlemek"** yerine **"öğrenmeyi"** gerçekleştirir.

VERİ ARTIRMA: Modelin genelleme yeteneğini artırmak için sentetik varyasyon oluşturma süreci.

| Sınıf Dengesizliği Çözümü



Weighted Binary Crossentropy

Çoklu etiketleme problemlerinde nadir hastalıkların (örn. Glokom) tespiti için:

- **Nadir sınıfların** eğitimdeki ağırlığı artırılarak modelin bu vakalara hassasiyeti yükseltildi.
- Modelin sadece "Normal" diyerek yüksek doğruluk alması (ezberlemesi) **engellendi**.
- Her bir etiket için **kayıp fonksiyonu** diğerlerinden bağımsız olarak optimize edildi.

DENGELEME STRATEJİSİ: Nadir hastalıkların teşhis başarısını artırmak için kullanılan matematiksel ceza yöntemi.

| Veri Kümesi Ayırıştırma

80%

Eğitim (Train)

10%

Doğrulama (Val)

10%

Test

Toplam Örnek Sayısı: 6392 Retina Görüntüsü

Modelin genellenebilirliğini sağlamak amacıyla veriler tabakalı olarak ayrılmıştır.

Eğitim seti modelin öğrenmesi, validasyon seti hiperparametre optimizasyonu, test seti ise final performansı ölçümü için kullanılmıştır..

Model Mimarisi

CNN Yapısı ve Eğitim Parametreleri

| Aktarımlı Öğrenme (Transfer Learning)

EfficientNetB0 Mimarisi

Projede sıfırdan bir model tasarlamak yerine, ImageNet üzerinde önceden eğitilmiş güçlü bir temel olan EfficientNetB0 mimarisi kullanılmıştır.

Düşük Veri Avantajı

Tıbbi veri setlerinin kısıtlı olması nedeniyle hazır bilgi birikimi kullanılmıştır.

Sabit Filtre Yapısı

Filtre sayıları ImageNet başarısı için optimize edildiğinden, hiperparametre olarak değiştirilmemiş, ağırlıklar korunmuştur.

EfficientNetB0 Tabanlı Mimari

Neden EfficientNetB0?

Model, ImageNet ağırlıkları ile ilklendirilmiş EfficientNetB0 mimarisini temel alır.

"Compound Scaling" yöntemi sayesinde derinlik, genişlik ve çözünürlük arasında optimal denge kurarak yüksek verimlilik sağlar.

Base Model	Trainable: False (1. Aşama)
Pooling	GlobalAveragePooling2D
Normalization	Batch Normalization
Activation	Sigmoid (Çok Etiketli Çıkış)



Özelleştirilmiş Üst Katmanlar

Fully Connected

256 nöronlu ReLU aktivasyonlu yoğun katman, öz niteliklerin hastalıklara özgü temsillerini öğrenir.

Regularizasyon

Dropout (0.35) ve Batch Normalization kullanılarak aşırı öğrenme (overfitting) engellenmiştir.

Çıkış Katmanı

8 adet hastalık sınıfı için Sigmoid aktivasyonu kullanılarak bağımsız olasılıklar üretilir.



Model Katmanları ve Parametreleri

Katman Tipi	Açıklama / Fonksiyon	Çıktı Şekli
EfficientNetB0	Dondurulmuş özellik çıkarıcı (Feature Extractor)	(None, 7, 7, 1280)
GlobalAvgPool2D	Boyut azaltma ve vektörleştirme	(None, 1280)
BatchNormalization	İçsel kovaryans kaymasını önleme	(None, 1280)
Dense (ReLU)	256 üniteli tam bağlantılı katman	(None, 256)
Dropout (0.35)	Ezberlemeyi (overfitting) engelleme	(None, 256)
Dense (Sigmoid)	8 sınıflı çoklu etiket çıktısı	(None, 8)

Dinamik Eşik Deęeri (Threshold Tuning) Stratejisi

Yöntem


Validation seti üzerinde her hastalık sınıfı için F1-skorunu maksimize eden dinamik eşik değeri optimize edilmiştir.

Gerekçe

Standart 0.5 eşięi, nadir hastalıkların (Glokom, Miyopi vb.) gözden kaçmasına ve düşük duyarlılıęa neden olmaktaydı.

Metrik Optimizasyonu

Her sınıf için Precision-Recall eğrisi taranarak, klinik hata payını en aza indiren kararlı sınırlar belirlenmiştir.



Model Karşılaştırma ve Performans Metrikleri

1. PR-AUC

Ne İşe Yarar: Eşiklerden bağımsız, ham algoritmik yeteneği ve ayırt etme zekasını ölçer.

Neden Seçtik: Aşırı sınıf dengesizliğinde en dürüst metriktir; nadir hastalıkları bulmadaki gerçek başarıyı yansıtır.

2. Macro F1-Score

Ne İşe Yarar: Olasılıklar karara dönüştüğünde net teşhis başarısını (Kesinlik/Duyarlılık) ölçer.

Neden Seçtik: Threshold Tuning başarısını ölçer; nadir hastalık tahmin başarısını doğrudan ödüllendirir.

3. Macro ROC-AUC


Ne İşe Yarar: Pozitif vakaya negatiften daha yüksek olasılık puanı verme yeteneğidir.

Neden Seçtik: Literatür kıyaslaması ve model ayırt etme gücü için güçlü bir baseline oluşturur.

4. Macro Recall

Ne İşe Yarar: Hasta gözlerin model tarafından % kaç oranında doğru yakalanabildiğini ölçer.

Gerekçe: Kritik medikal hata olan "Yalancı Negatifi" önlemek ve hiçbir hastayı gözden kaçırmamak içindir.



CNN Model Hiperparametreleri

Parametre	Açıklama ve CNN İçin Önemi
Base_line_model	Transfer learning yönteminde dondurulacak katman sayısını ve eğitime açılacak son katmanları belirleyen temel yapı taşıdır.
Batch Size	Modelin ağırlıkları güncellemeden önce işlediği veri sayısıdır. GPU kullanımını ve gradyan gürültüsüyle yerel minimumlardan kaçma yeteneğini belirler.
Epoch (Eğitim Turu)	Modelin veri setini tam tur geçmesidir. İlk turlarda temel özellikler (kenarlar) öğrenilirken, sonraki turlarda örüntüler netleşir ve ince ayar yapılır.
Dropout	Rastgele seçilen nöronların geçici olarak devre dışı bırakılmasıdır. Modelin ezberlemesini (overfitting) engeller ve genelleme yeteneğini artırır.
Learning Rate	Modelin hatayı düzeltmek için attığı adım büyüklüğüdür. En kritik parametredir; çok büyükse ıraksama, çok küçükse sonsuz eğitim veya yanlış noktada takılma riski taşır.

MODEL 1

Mimari

- EfficientNetB0
- 256 Üniteli Dense + BN + Dropout
- Dropout: 0.35
- Aktivasyon: Sigmoid
- Batch Size: 32

Eğitim Süreci

Aşama 1 (Klasik)

LR: 0.001 | 15 Epoch | Adam

Aşama 2 (Fine-Tuning)

Son 30 Katman Eğitilebilir | LR: 1e-5 | 30 Epoch

Threshold Stratejisi

Validasyon setine göre optimize edilmiş el ile ayarlanmış özel eşikler

Performans Özeti

Macro F1

0.3912

Recall

0.5640

ROC-AUC

0.7739

PR-AUC

0.4439



MODEL 2

Mimari

- EfficientNetB0
- 256 Üniteli Dense + BN + Dropout
- Dropout: 0.35
- Aktivasyon: Sigmoid
- Batch Size: 32

Eğitim Süreci

Aşama 1 (Klasik)

LR: 0.0005 | 15 Epoch | Adam

Aşama 2 (Fine-Tuning)

Son 30 Katman Eğitilebilir | LR: 1e-5 | 30 Epoch

Threshold Stratejisi

Validasyon setine göre optimize edilmiş el ile ayarlanmış özel eşikler

Performans Özeti

Macro F1
0.4449

Recall
0.5568

ROC-AUC
0.7877

PR-AUC
0.4546



Learning Rate Değişiminin Performansa Etkisi

Model 1 vs Model 2 Karşılaştırması

Model 1'de 0.001 olan başlangıç LR değeri, Model 2'de 0.0005'e düşürülmüştür. Bu daha hassas öğrenme adımı, özellikle sınıflandırma kararlılığında (Macro F1 ve Recall) belirgin iyileşme sağlamıştır.

Macro F1 Gelişimi



0.3912 → 0.4449


Daha düşük LR, kesinlik ve duyarlılık dengesini artırdı.

Recall Gelişimi



0.5640 → 0.5568

Model 2'de Recall hafif düşerken F1 skoru belirgin artmıştır.



MODEL 3

Mimari

- EfficientNetB0
- Base Line Model: 45
- Dropout: 0.45
- Aktivasyon: Sigmoid
- Batch Size: 64

Eğitim Süreci

Aşama 1 (Klasik)

LR: 0.0005 | 15 Epoch | Adam

Aşama 2 (Fine-Tuning)

Son 45 Katman Eğitilebilir | LR: 1e-5 | 35 Epoch

Threshold Stratejisi

Validasyon setine göre optimize edilmiş el ile ayarlanmış özel eşikler

Performans Özeti

Macro F1

0.4624

Macro Recall

0.584

Macro ROC-AUC

0.8014

Macro PR-AUC

0.4734




Model 2 vs Model 3: Optimizasyon Etkisi

Mimari Değişikliklerin Performans Analizi

Model 3'te base_line_model 45'e, dropout 0.45'e ve batch_size 64'e çıkarılmıştır. Bu yapılandırma, özellikle Recall (0.55'ten 0.58'e) ve PR-AUC metriklerinde belirgin bir sıçrama sağlayarak modelin teşhis kapasitesini güçlendirmiştir.


Recall Artışı



0.55 → 0.58

Daha derin fine-tuning ile yakalanan pozitif vaka oranı arttı.

PR-AUC Gelişimi



0.4449 → 0.4734

Yüksek batch size ve regülasyon hassasiyeti artırdı.



MODEL 4

Mimari

- EfficientNetB0
- Base Line Model: 45
- Dropout: 0.45
- Aktivasyon: Sigmoid
- Batch Size: 64

Eğitim Süreci

Aşama 1 (Klasik)

LR: 0.0005 | 35 Epoch | Adam

Aşama 2 (Fine-Tuning)

Son 45 Katman Eğitilebilir | LR: 1e-5 | 35 Epoch

Threshold Stratejisi

Validasyon setine göre optimize edilmiş el ile ayarlanmış özel eşikler

Performans Özeti

Macro F1

0.4454

Macro Recall

0.5836

Macro ROC-AUC

0.7805

Macro PR-AUC

0.4583



Model 3 vs Model 4: Performans Karşılaştırması

Model 3 ve Model 4 Metrik Analizi

Model 4'te artırılan epoch sayısı, Model 3 ile kıyaslandığında Recall değerinde sınırlı bir değişim (+%1.2) yaratırken, Macro F1 (-%6.3) ve ROC-AUC gibi temel metriklerde belirgin bir düşüşe neden olmuştur.

Macro F1 Farkı

+%1.2

0.4624 → 0.4454

Aşırı eğitim, modelin genel başarısını ve dengesini düşürdü.

ROC-AUC Kaybı

-2.6%

0.8014 → 0.7805

Ayırt etme gücü epoch artışıyla olumsuz etkilendi.



Sonuç: En İyi Performans Veren Model

Model 3: Optimal Denge ve Yüksek Başarı

Yapılan analizler sonucunda **Model 3**, tüm metriklerde en dengeli ve yüksek performansı sergileyen yapı olarak belirlenmiştir. Aşırı öğrenmeye (overfitting) düşmeden, hem teşhis kapasitesini hem de genel ayırt ediciliğini korumayı başarmıştır.

Macro F1

0.4624

Recall

0.5840

ROC-AUC

0.8014

PR-AUC

0.4734

Neden Model 3?

- Özellikle **PR-AUC (+%6.4)** ve **Recall (+%5.5)** artışıyla teşhis kapasitesi maksimize edilmiştir.
- Model 4'teki gibi epoch artışının getirdiği performans kaybı yaşanmamıştır.
- Daha yüksek batch size (64) ve optimize dropout (0.45) ile en yüksek stabiliteye ulaşmıştır.




Eğitim Süreci: Loss Analizi

Training vs Validation Loss Grafiği

Bu grafik modelin öğrenme sürecini gösterir. Loss değerinin epoch ilerledikçe azalması modelin veriyi başarılı şekilde öğrendiğini göstermektedir. Validation loss'un da kontrollü şekilde azalması modelin **overfitting** yapmadan genelleme başarısı elde ettiğini kanıtlar.

Model Öğrenme Performansı

Hata oranlarındaki istikrarlı düşüş



Grafik Ne Anlatıyor?

- **X eksen:** Epoch sayısını ifade eder.
- **Y eksen:** Loss (hata) değerini gösterir.
- **Train Loss:** 1.27'den 0.76'ya düşerek çok iyi bir öğrenme eğrisi sergilemiştir.
- **Validation Loss:** 1.00'den 0.89 civarına inerek daha stabil bir seyir izlemiştir.


Eğitim Süreci: PR-AUC Analizi

PR-AUC Grafiği ve Anlamı

PR-AUC (Precision-Recall Area Under Curve), modelin **sınıfları birbirinden ayırabilme gücünü** gösterir. Değerin yüksek olması, modelin sınıfları ayırt etme performansının güçlü olduğunu kanıtlar. Eğri altındaki alan arttıkça modelin doğruluğu ve hassasiyeti artar.

Model Ayırt Etme Gücü

Yüksek PR-AUC ile optimize teşhis kapasitesi



- Validation eğrisinin stabil ilerlemesi, modelin **genelleme kabiliyetinin** korunduğunu gösterir.
- Fine-tuning başlangıcı sonrası Train AUC artışı, modelin spesifik özellikleri başarıyla yakaladığını kanıtlar.
- PR-AUC skoru, dengesiz veri setlerinde model başarısının en kritik göstergesidir.

Sınıf Bazlı Model Performans Analizi


Multi-label Sınıf Bazlı F1-Score Dağılımı

Grafik, modelin farklı tıbbi sınıflar üzerindeki başarı oranlarını (F1-Score) göstermektedir. En yüksek performans **M (0.75)** ve **C (0.72)** sınıflarında görülürken, en düşük performans **H (0.18)** ve **A (0.20)** sınıflarında saptanmıştır.



Temel Bulgular


- **Dominant Sınıflar:** M ve C sınıfları %70 başarının üzerinde kalarak modelin en güçlü olduğu alanları temsil eder.
- **Orta Segment:** N, D ve O sınıfları %40-%60 bandında dengeli bir performans sergilemektedir.
- **Kritik Eksiklik:** H, A ve G sınıflarındaki düşük skorlar, veri setindeki dengesizliğe veya öznelite karmaşıklığına işaret etmektedir.



Sınıf Bazlı PR-AUC ve ROC-AUC Analizi

Metrik Karşılaştırması ve Model Kabiliyeti

Grafik, modelin farklı tıbbi sınıflar (N, D, G, C, A, H, M, O) üzerindeki **PR-AUC** ve **ROC-AUC** değerlerini sergilemektedir. ROC-AUC değerleri genel olarak daha yüksek seyrederken, PR-AUC değerleri sınıf bazlı hassasiyeti daha net yansıtmaktadır.




Temel Bulgular

- **En Başarılı Sınıf:** C ve M sınıfları, hem PR-AUC hem de ROC-AUC değerlerinde %80 eşliğini aşarak en güvenilir tahminleri üretmektedir.
- **Düşük Performans:** H sınıfı, özellikle PR-AUC değerinde ciddi bir düşüş göstererek modelin bu sınıftaki pozitif örnekleri ayırt etmede zorlandığını kanıtlamaktadır.
- **Veri Dengesizliği Etkisi:** PR-AUC değerlerinin ROC-AUC'ye göre belirgin düşük olduğu A ve H gibi sınıflar, veri集中的 seyreklik veya öznitelik karmaşıklığına işaret eder.

Metrik Analizi ve Sınıf Bazlı Performans Yorumları

Model Tahmin Kapasitesi ve Hata Analizi



Sınıf Bazlı Bulgular

- **C (Katarakt):** Üç metrik (0.73) eşit ve dengeli. Threshold (0.90) kalibrasyonu ile yanlış alarm oranı düşük.
- **M (Miyopi):** En yüksek performanslı sınıf (F1: 0.77). Yüksek threshold değerine rağmen ayırt edici özellikler çok belirgin.
- **N & D:** Recall, Precision'dan yüksek. Model aşırı pozitif tahmin eğiliminde; gerçek vakaları yakalıyor ancak yanlış alarm veriyor.
- **G (Glokom):** Precision (0.25) düşük. Veri azlığı öğrenmeyi kısıtlıyor, yüksek threshold bile yanlış pozitifleri önleyememiş.
- **A (AMD):** Her 8 pozitif tahminden sadece 1'i doğru (Precision: 0.12). Model bu sınıfı aşırı tahmin ediyor.
- **H (Hipertansiyon):** En düşük performans (F1: 0.21). Veri yetersizliği nedeniyle patoloji öğrenilememiş.

Sonuç ve Gelecek Vizyonu

Fundus Görüntüleme ve Teşhis Zorlukları


Retinal fundus resimleri, düşük kontrast ve **morfolojik benzerlikler** nedeniyle analiz edilmesi en güç tıbbi verilerdendir. Damar yapıları ve lezyonların ayrımı, yüksek hassasiyetli derin öğrenme mimarileri gerektirir.

Neler Öğrendik?

- **Veri Dengesi:** Nadir görülen sınıfların (H, A) model başarısını doğrudan etkilediği görüldü.
- **Hyperparameter:** Batch size ve dropout oranlarının overfitting üzerinde kritik rolü anlaşıldı.
- **Metrik Seçimi:** PR-AUC'nin dengesiz veri setlerinde en güvenilir rehber olduğu teyit edildi.

Gelecek Çalışmalar

- **Data Augmentation:** GAN tabanlı veri üretimi ile azınlık sınıfların desteklenmesi.
- **Ensemble Learning:** Farklı mimarilerin (ViT ve CNN) birleştirilerek hata payının düşürülmesi.
- **Explainable AI:** Teşhislerin klinik güvenilirliğini artırmak için Grad-CAM entegrasyonu.



Hazırlayanlar

Proje Ekibi

Özcan Kocaman

Betül Balcı

Serra Demirel

Sedef Birgül

Zehra Yılmaz